Comparativo de Modelos LLM

Contexto

Durante o desenvolvimento do projeto, testamos quatro modelos para geração de respostas do assistente. O objetivo era encontrar um modelo que equilibrasse qualidade de resposta, disponibilidade em nuvem e limites de uso aceitáveis.

Modelos Avaliados

Critério	LLaMA 3 70B	LLaMA 3 8B	Qwen 2.5 3B	Qwen 2.5 1.5B
Qualidade das respostas	Alta	Boa	Fraca	Fraca
Execução	Nuvem (Groq)	Nuvem (Groq)	Local	Local
Rate limit	Estourava rápido	Adequado	N/A	N/A
Escalabilidade	Limitada	Boa	Sem escala	Sem escala
Resultado dos testes	Descartado	**Escolhido**	Descartado	Descartado

---

Análise por Modelo

LLaMA 3 70B

- Gerava respostas de alta qualidade e com boa compreensão de contexto
- Rodava via nuvem, sem necessidade de infraestrutura local
- **Problema:** o rate limit era atingido muito rapidamente, inviabilizando o uso em produção com múltiplos usuários simultâneos

LLaMA 3 8B — Modelo Escolhido

- Qualidade de resposta satisfatória para o caso de uso do projeto
- Roda em nuvem com rate limit significativamente mais generoso do que o 70B
- Boa relação entre qualidade e disponibilidade
- Viável para produção sem risco iminente de throttling

Qwen 2.5 3B

- Qualidade de resposta abaixo do esperado para o domínio do projeto
- Exige execução local, o que impõe limitações de escalabilidade e infraestrutura
- Descartado pela combinação de baixa qualidade e ausência de escala em nuvem

Qwen 2.5 1.5B

- Qualidade ainda inferior ao Qwen 3B
- Mesmas limitações de execução local

- Descartado pelos mesmos motivos, com desempenho ainda mais fraco

---

Decisão Final

Modelo escolhido: LLaMA 3 8B

O LLaMA 3 8B foi selecionado por rodar em nuvem com um rate limit adequado ao volume esperado da aplicação, entregando qualidade de resposta aceitável para o contexto do projeto. O 70B, apesar da superioridade técnica, tornava-se inviável pelo consumo acelerado de cota. Os modelos Qwen, além de não gerarem resultados satisfatórios, exigiam infraestrutura local, o que conflita com os requisitos de escalabilidade e deploy em nuvem do projeto.